Detecção de Anomalias em Logs de Eventos: Modelo Sintético da Disciplina e Dados Reais Utilizados em X-Processes

Vanderleia Matos Costa e colaboradores

SIN5025 — Mineração de Processos
Universidade de São Paulo

***Abstract*—Estudam-se anomalias em duas fontes distintas: uma amostra de 500 casos do log sintético gerado no BIMP a partir do modelo XML da disciplina e o conjunto observacional BPIC12, utilizado pelos autores de X-Processes. No sintético, 25 casos da amostra foram modificados; raridade_transicoes: F1 0,920. Para o experimento real, 1000 casos foram escolhidos e 200 foram modificados artificialmente (20%). Os resultados desta edição são lidos dos arquivos summary.json após cada execução. Apenas métodos concluídos recebem métricas; falhas e ausências aparecem no estado da execução. O BPI possui casos reais, mas os rótulos deste experimento indicam modificações controladas, e não anomalias naturais comprovadas.**

***Index Terms*—mineração de processos, detecção de anomalias, XES, dados reais, simulação**

I. Introdução

Um log de eventos reúne atividades, instante e identificador de caso. Uma sequência cronológica de atividades é um trace. A qualidade dos registros importa para descobrir processos, comparar comportamentos e investigar exceções. Um caso incomum não é necessariamente incorreto: escolhas válidas, paralelismo e mudanças do processo podem gerar sequências raras [1], [2].

O objetivo é explicar o que se chama anomalia, quais desvios podem ser detectados e tratados e como comparar resultados em fontes sintética e observacional. Os autores Fantinato, Peres e Reijers aplicaram X-Processes a 12 logs reais para descobrir modelos [3]; aqui se estuda detecção de alterações em um dos mesmos conjuntos, BPIC12. Não são reproduzidos os resultados de qualidade de descoberta como se fossem métricas de anomalias.

II. Definição e identificação

Seja $\sigma = \langle a_1, \ldots, a_m \rangle$ um trace. Neste experimento rotulado, anomalia significa uma edição deliberada em uma cópia de σ, com tipo e identificador registrados. Essa definição operacional permite medir acerto comparando a observação com a cópia anterior. Em produção, atividade rara, atividade inexistente, repetição indevida, omissão e troca de ordem são apenas indícios; confirmar anomalia requer conhecer regras, exceções e contexto [4].

A. Estratégias de detecção

Modelos normativos e verificações de conformidade permitem confrontar o trace com comportamento permitido; escores de raridade de transições comparam pares consecutivos; LOF estima densidade relativa; Isolation Forest procura casos isolados; redes neurais podem aprender representações de eventos. Um limiar ou orçamento de alertas converte ranking em suspeitas. O BPMN do experimento sintético serve à simulação, sem ser inserido como rótulo no método estatístico [5], [6].

TABLE I
RESULTADOS DA AMOSTRA SINTÉTICA DE 500 CASOS

Método	P	R	F1
raridade_transicoes	0,920	0,920	0,920

III. QUAIS ANOMALIAS PODEM SER TRATADAS?

Omissão de atividade, repetição de registro, permuta de atividades e inserção de atividade desconhecida são alterações estruturais controláveis por edição da sequência. Também existem desvios de tempo, recurso, atributo de dado e relação entre objetos: como o programa desta experiência utiliza somente atividades por caso, não se deve alegar que essas últimas categorias foram medidas. Campos de tempo e recurso podem ser analisados em trabalhos posteriores.

Há alternativas de tratamento: preservar e encaminhar à revisão, corrigir um erro confirmado, adicionar evento faltante com evidência externa, remover duplicata comprovada, normalizar códigos de atividade, ou atualizar o modelo se o comportamento raro for legítimo. Uma sugestão de reparo baseada em protótipos observados não equivale à restauração comprovada sem comparação com referência limpa. Deve-se registrar original, justificativa, edição e responsável [7], [4].

IV. DADOS SINTÉTICOS DA PROFESSORA

A professora Sarajane Marques Peres disponibilizou "Modelo de processo (fonte / XML genérico) — Para ser usado no simulador". A visualização no Bizagi Modeler mostrou 26 atividades de A até Z, decisões XOR, ramificações paralelas, reconvergências, um retorno de fluxo e mais de uma possibilidade de término. A versão BPMN exportada acompanha o projeto sintético. O modelo não foi substituído por um fluxo próprio mais simples.

Após configurar o processo no BIMP, incluindo durações, recursos e probabilidades das saídas XOR, foram gerados 5.000 casos em MXML compactado. Preservou-se o log limpo e, em uma cópia, um script Python modificou 250 casos (5%), com semente 2026. O projeto extrai uma amostra controlada de 500 desses casos: 25 rotulados como alterados e 475 não alterados, mantendo os mesmos IDs nos arquivos limpo e anômalo. Os tipos foram inserção final de A, omissão de A, repetição de A e substituição de A por Z. Os rótulos são externos ao arquivo pontuado. Não se infere do log a configuração exata de todas as probabilidades usadas no simulador.

V. RESULTADO SINTÉTICO REGISTRADO

O código calcula escores e confronta alertas com o arquivo externo de rótulos da amostra. A Tabela I é atualizada depois da execução sintética. São comparados 500 casos, sendo 25 alterados; uma tabela vazia significa que ainda não há execução concluída, e não que o resultado seja zero. Os arquivos de caso preservam a pontuação e a decisão para auditoria.

VI. Origem dos dados reais

O BPIC12, do BPI Challenge 2012, é um log observacional de solicitações de empréstimo disponibilizado por van Dongen no repositório 4TU [8]. A Tabela 6 do artigo X-Processes [3] inclui BPIC12 entre os 12 logs de referência e reporta 13.087 casos, 262.200 eventos, 24 atividades e 4.366 variantes; o arquivo XES.GZ incluído neste projeto tem esses totais. O repositório X-Processes também contém um arquivo denominado test.xes.gz; esse arquivo menor não é o BPIC12 usado aqui. A coincidência de nome e estatísticas identifica o conjunto de origem; a contribuição experimental desta pesquisa é uma tarefa nova de detecção.

VII. Protocolo XES e prevenção de vazamento

O comando preparar_xes.py lê o XES original sem modificá-lo, seleciona casos elegíveis de forma determinística e grava uma amostra limpa em XES.GZ. Sua cópia modificada recebe uma das quatro operações: omissão de evento interno, repetição de evento, troca dos nomes das duas primeiras atividades e inserção de atividade `__UNKNOWN__`. A tabela externa identifica os casos alterados e preserva suas sequências antes/depois. Nessa execução: 1000 casos, 200 modificações, taxa 20%, distribuição omissao: 50, repeticao: 50, troca: 50, atividade_desconhecida: 50.

O importador converte o XES alterado para a estrutura esperada pelos 14 métodos BPAD, em que todos os exemplos são marcados como normais na entrada. O arquivo de referência é aberto pelo programa apenas para avaliar pontuações e sugestões. O protocolo compara traces reais aos mesmos traces após ruído artificial. A organização original não forneceu uma lista de anomalias naturais para esses casos, logo métricas de precisão e F1 não devem ser interpretadas como validação de fraude ou irregularidade real.

VIII. Métricas e reparação

Após fixar o orçamento de alertas, $P = TP/(TP + FP)$, $R = TP/(TP+FN)$ e $F_1 = 2PR/(P+R)$. AP e AUC-ROC avaliam a ordenação por escore. Uma correção proposta pode ser contada como exata apenas se igualar a cópia limpa do trace, evento por evento na perspectiva escolhida; a contagem de sugestões aplicadas, por si só, não comprova recuperação. O erro do método deve permanecer visível quando ocorrer.

TABLE II
EXPERIMENTO REAL ANTERIOR: QUATRO BASELINES, 1.000 CASOS

Método	F1	AUC
raridade_transicoes	0.625	0.836
local_outlier_factor	0.450	0.812
isolation_forest	0.305	0.717
consenso_ranks	0.420	0.798

TABLE III
RESULTADOS REAIS CONTROLADOS; SOMENTE EXECUÇÕES CONCLUÍDAS

Método	P	R	F1	AUC
likelihood	0,395	0,395	0,395	0,759
naive	0,255	0,255	0,255	0,664
sampling	0,275	0,275	0,275	0,666
dae	0,245	0,245	0,245	0,542
binetv3	0,360	0,360	0,360	0,700
binetv2	0,420	0,420	0,420	0,620
gama	0,450	0,450	0,450	0,803
vae	0,385	0,385	0,385	0,739
lae	0,375	0,375	0,375	0,569
gae	0,170	0,170	0,170	0,493
grasped	0,305	0,305	0,305	0,652
leverage	0,060	0,060	0,060	0,403
w2vlof	0,465	0,465	0,465	0,757
vaeocsvm	0,200	0,200	0,200	0,512

IX. RESULTADOS GERADOS PARA O LOG REAL

O projeto também preserva um experimento anterior com quatro métodos de referência em 1.000 casos BPIC12, com 200 casos corrompidos artificialmente; suas métricas são mostradas separadamente. A tabela dos 14 métodos é construída com entradas cujo status é ok em results/bpic12-anomalias/summary.json. Métodos não concluídos não recebem valores substitutos. Nenhum desses números é atribuído ao artigo X-Processes.

X. LEITURA RESPONSÁVEL DOS RESULTADOS

Mesmo que todos os detectores executem, a proporção de alertas e a taxa de corrupção determinam parte das métricas observadas. Como a comparação utiliza apenas atividades e uma edição por caso, o teste não mede anomalias de recurso ou tempo. Um resultado de reparação é auditável consultando os arquivos de escores, casos e sugestões no mesmo diretório. Para comparar taxas de ruído, devem-se repetir execuções com sementes e parâmetros explícitos; somente então se pode calcular intervalos de variação.

TABLE IV
ESTADO DOS 14 MÉTODOS DISPONIBILIZADOS

Método	Estado
likelihood	ok
naive	ok
sampling	ok
dae	ok
binetv3	ok
binetv2	ok
gama	ok
vae	ok
lae	ok
gae	ok
grasped	ok
leverage	ok
w2vlof	ok
vaeocsvm	ok

XI. Falhas, limites e interpretação

Cada implementação legada é executada isoladamente. Se faltarem dependências ou houver incompatibilidades de versão, o método recebe status failed e erro em summary.json. A tabela abaixo registra as falhas desta execução, sem convertê-las em sucessos.

- Nenhuma falha registrada entre os métodos solicitados nesta etapa.

O X-Processes otimiza modelos descobertos, com foco em adequação, precisão, generalização e simplicidade [3]. Essas medidas não são sinônimas de precisão, revocação e F1 de um detector de casos alterados. O log real pode conter comportamentos raros perfeitamente legítimos; sem validação de especialistas, o protocolo só estabelece capacidade de recuperar mudanças que ele mesmo introduziu. A amostra também não prova transferência de um método treinado sobre o modelo da professora para processos financeiros.

XII. Reprodutibilidade

Este pacote mantém os logs em data/sintetico e data/real, sob um mesmo diretório de projeto. Execute executar_sintetico.py para pontuar os 500 casos MXML ou executar_real.py para os casos XES. Cada comando gera um resumo de métodos e recompila este relatório a partir dos resultados presentes. Confira rotulos.csv externo, escores por caso e status antes de usar as tabelas. O PDF depende de pdfLaTeX e BibTeX; o arquivo .tex é sempre escrito. Não é necessário instalar X-Processes para executar BPAD: a referência ao estudo identifica o conjunto real escolhido.

XIII. Conclusão

O modelo da disciplina, iniciado no XML fornecido e executado no BIMP, permite avaliação controlada porque o log limpo foi preservado. Na amostra de 500 casos, raridade_transicoes: F1 0,920. O BPIC12 fornece casos observacionais empregados também pelos pesquisadores de X-Processes; aqui uma cópia recebe alterações controladas para permitir medir detecção e estudar sugestões de reparo. A versão real contém 14 método(s) concluído(s) entre 14 solicitados; as tabelas descrevem apenas números gravados. Sem rótulos humanos de anomalias naturais, recomenda-se revisão humana e repetições com diferentes sementes e taxas.

References

[1] W. M. P. van der Aalst, *Process Mining: Data Science in Action*, 2nd ed. Springer, 2016.

[2] W. M. P. van der Aalst and J. Carmona, Eds., *Process Mining Handbook*, ser. Lecture Notes in Business Information Processing. Springer, 2022, vol. 448.

[3] M. Fantinato, S. M. Peres, and H. A. Reijers, "X-Processes: Process model discovery with the best balance among fitness, precision, simplicity, and generalization through a genetic algorithm," *Information Systems*, vol. 119, p. 102247, 2023.

[4] S. Suriadi, R. Andrews, A. H. M. ter Hofstede, and M. T. Wynn, "Event log imperfection patterns for process mining: Towards a systematic approach to cleaning event logs," *Information Systems*, vol. 64, pp. 132–150, 2017.

[5] M. M. Breunig, H.-P. Kriegel, R. T. Ng, and J. Sander, "LOF: Identifying density-based local outliers," in *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, 2000, pp. 93–104.

[6] F. T. Liu, K. M. Ting, and Z.-H. Zhou, "Isolation forest," in *2008 Eighth IEEE International Conference on Data Mining*, 2008, pp. 413–422.

[7] M. Weske, *Business Process Management: Concepts, Languages, Architectures*, 4th ed. Springer, 2024.

[8] B. F. van Dongen, "BPI Challenge 2012," Dataset, 2012. [Online]. Available: https://data.4tu.nl/articles/dataset/BPI_Challenge_2012/12689204