# Detecção de Anomalias em Logs de Eventos: Modelo Sintético da Disciplina e Dados Reais Utilizados em X-Processes

Vanderleia Matos Costa e colaboradores

SIN5025 — Mineração de Processos
Universidade de São Paulo

***Abstract*—Estudam-se anomalias em duas fontes distintas: uma amostra de 500 casos do log sintético gerado no BIMP a partir do modelo XML da disciplina e o conjunto observacional BPIC12, utilizado pelos autores de X-Processes. No sintético, 25 casos da amostra foram modificados; raridade_transicoes: F1 0,920. Para o experimento real, 1000 casos foram escolhidos e 200 foram modificados artificialmente (20%). Os resultados desta edição são lidos dos arquivos summary.json após cada execução. Apenas métodos concluídos recebem métricas; falhas e ausências aparecem no estado da execução. O BPI possui casos reais, mas os rótulos deste experimento indicam modificações controladas, e não anomalias naturais comprovadas.**

***Index Terms*—mineração de processos, detecção de anomalias, XES, dados reais, simulação**

## I. Introdução

Um log de eventos reúne atividades, instante e identificador de caso. Uma sequência cronológica de atividades é um trace. A qualidade dos registros importa para descobrir processos, comparar comportamentos e investigar exceções. Um caso incomum não é necessariamente incorreto: escolhas válidas, paralelismo e mudanças do processo podem gerar sequências raras [1], [2].

O objetivo é explicar o que se chama anomalia, quais desvios podem ser detectados e tratados e como comparar resultados em fontes sintética e observacional. Os autores Fantinato, Peres e Reijers aplicaram X-Processes a 12 logs reais para descobrir modelos [3]; aqui se estuda detecção de alterações em um dos mesmos conjuntos, BPIC12. Não são reproduzidos os resultados de qualidade de descoberta como se fossem métricas de anomalias.

## II. Definição e identificação

Seja $\sigma = \langle a_1, \ldots, a_m \rangle$ um trace. Neste experimento rotulado, anomalia significa uma edição deliberada em uma cópia de $\sigma$, com tipo e identificador registrados. Essa definição operacional permite medir acerto comparando a observação com a cópia anterior. Em produção, atividade rara, atividade inexistente, repetição indevida, omissão e troca de ordem são apenas indícios; confirmar anomalia requer conhecer regras, exceções e contexto [4].

### A. Estratégias de detecção

Modelos normativos e verificações de conformidade permitem confrontar o trace com comportamento permitido; escores de raridade de transições comparam pares consecutivos; LOF estima densidade relativa; Isolation Forest procura casos isolados; redes neurais podem aprender representações de eventos. Um limiar ou orçamento de alertas converte ranking em suspeitas. O BPMN do experimento sintético serve à simulação, sem ser inserido como rótulo no método estatístico [5], [6].

TABLE I
RESULTADOS DA AMOSTRA SINTÉTICA DE 500 CASOS

| Método | P | R | F1 |
|---|---|---|---|
| raridade_transicoes | 0,920 | 0,920 | 0,920 |

## III. QUAIS ANOMALIAS PODEM SER TRATADAS?

Omissão de atividade, repetição de registro, permuta de atividades e inserção de atividade desconhecida são alterações estruturais controláveis por edição da sequência. Também existem desvios de tempo, recurso, atributo de dado e relação entre objetos: como o programa desta experiência utiliza somente atividades por caso, não se deve alegar que essas últimas categorias foram medidas. Campos de tempo e recurso podem ser analisados em trabalhos posteriores.

Há alternativas de tratamento: preservar e encaminhar à revisão, corrigir um erro confirmado, adicionar evento faltante com evidência externa, remover duplicata comprovada, normalizar códigos de atividade, ou atualizar o modelo se o comportamento raro for legítimo. Uma sugestão de reparo baseada em protótipos observados não equivale à restauração comprovada sem comparação com referência limpa. Deve-se registrar original, justificativa, edição e responsável [7], [4].

## IV. DADOS SINTÉTICOS DA PROFESSORA

A professora Sarajane Marques Peres disponibilizou "Modelo de processo (fonte / XML genérico) — Para ser usado no simulador". A visualização no Bizagi Modeler mostrou 26 atividades de A até Z, decisões XOR, ramificações paralelas, reconvergências, um retorno de fluxo e mais de uma possibilidade de término. A versão BPMN exportada acompanha o projeto sintético. O modelo não foi substituído por um fluxo próprio mais simples.

Após configurar o processo no BIMP, incluindo durações, recursos e probabilidades das saídas XOR, foram gerados 5.000 casos em MXML compactado. Preservou-se o log limpo e, em uma cópia, um script Python modificou 250 casos (5%), com semente 2026. O projeto extrai uma amostra controlada de 500 desses casos: 25 rotulados como alterados e 475 não alterados, mantendo os mesmos IDs nos arquivos limpo e anômalo. Os tipos foram inserção final de A, omissão de A, repetição de A e substituição de A por Z. Os rótulos são externos ao arquivo pontuado. Não se infere do log a configuração exata de todas as probabilidades usadas no simulador.

## V. RESULTADO SINTÉTICO REGISTRADO

O código calcula escores e confronta alertas com o arquivo externo de rótulos da amostra. A Tabela I é atualizada depois da execução sintética. São comparados 500 casos, sendo 25 alterados; uma tabela vazia significa que ainda não há execução concluída, e não que o resultado seja zero. Os arquivos de caso preservam a pontuação e a decisão para auditoria.

## VI. Origem dos dados reais

O BPIC12, do BPI Challenge 2012, é um log observacional de solicitações de empréstimo disponibilizado por van Dongen no repositório 4TU [8]. A Tabela 6 do artigo X-Processes [3] inclui BPIC12 entre os 12 logs de referência e reporta 13.087 casos, 262.200 eventos, 24 atividades e 4.366 variantes; o arquivo XES.GZ incluído neste projeto tem esses totais. O repositório X-Processes também contém um arquivo denominado test.xes.gz; esse arquivo menor não é o BPIC12 usado aqui. A coincidência de nome e estatísticas identifica o conjunto de origem; a contribuição experimental desta pesquisa é uma tarefa nova de detecção.

## VII. Protocolo XES e prevenção de vazamento

O comando preparar_xes.py lê o XES original sem modificá-lo, seleciona casos elegíveis de forma determinística e grava uma amostra limpa em XES.GZ. Sua cópia modificada recebe uma das quatro operações: omissão de evento interno, repetição de evento, troca dos nomes das duas primeiras atividades e inserção de atividade `__UNKNOWN__`. A tabela externa identifica os casos alterados e preserva suas sequências antes/depois. Nessa execução: 1000 casos, 200 modificações, taxa 20%, distribuição omissao: 50, repeticao: 50, troca: 50, atividade_desconhecida: 50.

O importador converte o XES alterado para a estrutura esperada pelos 14 métodos BPAD, em que todos os exemplos são marcados como normais na entrada. O arquivo de referência é aberto pelo programa apenas para avaliar pontuações e sugestões. O protocolo compara traces reais aos mesmos traces após ruído artificial. A organização original não forneceu uma lista de anomalias naturais para esses casos, logo métricas de precisão e F1 não devem ser interpretadas como validação de fraude ou irregularidade real.

## VIII. Métricas e reparação

Após fixar o orçamento de alertas, $P = TP/(TP + FP)$, $R = TP/(TP+FN)$ e $F_1 = 2PR/(P+R)$. AP e AUC-ROC avaliam a ordenação por escore. Uma correção proposta pode ser contada como exata apenas se igualar a cópia limpa do trace, evento por evento na perspectiva escolhida; a contagem de sugestões aplicadas, por si só, não comprova recuperação. O erro do método deve permanecer visível quando ocorrer.

TABLE II
EXPERIMENTO REAL ANTERIOR: QUATRO BASELINES, 1.000 CASOS

| Método | F1 | AUC |
|---|---|---|
| raridade_transicoes | 0.625 | 0.836 |
| local_outlier_factor | 0.450 | 0.812 |
| isolation_forest | 0.305 | 0.717 |
| consenso_ranks | 0.420 | 0.798 |

TABLE III
RESULTADOS REAIS CONTROLADOS; SOMENTE EXECUÇÕES CONCLUÍDAS

| Método | P | R | F1 | AUC |
|---|---|---|---|---|
| likelihood | 0,395 | 0,395 | 0,395 | 0,759 |
| naive | 0,255 | 0,255 | 0,255 | 0,664 |
| sampling | 0,275 | 0,275 | 0,275 | 0,666 |
| dae | 0,245 | 0,245 | 0,245 | 0,542 |
| binetv3 | 0,360 | 0,360 | 0,360 | 0,700 |
| binetv2 | 0,420 | 0,420 | 0,420 | 0,620 |
| gama | 0,450 | 0,450 | 0,450 | 0,803 |
| vae | 0,385 | 0,385 | 0,385 | 0,739 |
| lae | 0,375 | 0,375 | 0,375 | 0,569 |
| gae | 0,170 | 0,170 | 0,170 | 0,493 |
| leverage | 0,060 | 0,060 | 0,060 | 0,403 |
| w2vlof | 0,465 | 0,465 | 0,465 | 0,757 |
| vaeocsvm | 0,200 | 0,200 | 0,200 | 0,512 |

## IX. RESULTADOS GERADOS PARA O LOG REAL

O projeto também preserva um experimento anterior com quatro métodos de referência em 1.000 casos BPIC12, com 200 casos corrompidos artificialmente; suas métricas são mostradas separadamente. A tabela dos 14 métodos é construída com entradas cujo status é ok em results/bpic12-anomalias/summary.json. Métodos não concluídos não recebem valores substitutos. Nenhum desses números é atribuído ao artigo X-Processes.

## X. LEITURA RESPONSÁVEL DOS RESULTADOS

Mesmo que todos os detectores executem, a proporção de alertas e a taxa de corrupção determinam parte das métricas observadas. Como a comparação utiliza apenas atividades e uma edição por caso, o teste não mede anomalias de recurso ou tempo. Um resultado de reparação é auditável consultando os arquivos de escores, casos e sugestões no mesmo diretório. Para comparar taxas de ruído, devem-se repetir execuções com sementes e parâmetros explícitos; somente então se pode calcular intervalos de variação.

TABLE IV
ESTADO DOS 14 MÉTODOS DISPONIBILIZADOS

| Método | Estado |
|---|---|
| likelihood | ok |
| naive | ok |
| sampling | ok |
| dae | ok |
| binetv3 | ok |
| binetv2 | ok |
| gama | ok |
| vae | ok |
| lae | ok |
| gae | ok |
| grasped | failed |
| leverage | ok |
| w2vlof | ok |
| vaeocsvm | ok |

## XI. Falhas, limites e interpretação

Cada implementação legada é executada isoladamente. Se faltarem dependências ou houver incompatibilidades de versão, o método recebe status failed e erro em summary.json. A tabela abaixo registra as falhas desta execução, sem convertê-las em sucessos.

- `grasped`: ImportError: cannot import name 'Iterator' from 'collections' (/home/vanderleia/.local/share/uv/python/cpython-3.13.15-linux-x86_64-gnu/lib/python3.13/coll.

O X-Processes otimiza modelos descobertos, com foco em adequação, precisão, generalização e simplicidade [3]. Essas medidas não são sinônimas de precisão, revocação e F1 de um detector de casos alterados. O log real pode conter comportamentos raros perfeitamente legítimos; sem validação de especialistas, o protocolo só estabelece capacidade de recuperar mudanças que ele mesmo introduziu. A amostra também não prova transferência de um método treinado sobre o modelo da professora para processos financeiros.

## XII. Reprodutibilidade

Este pacote mantém os logs em data/sintetico e data/real, sob um mesmo diretório de projeto. Execute executar_sintetico.py para pontuar os 500 casos MXML ou executar_real.py para os casos XES. Cada comando gera um resumo de métodos e recompila este relatório a partir dos resultados presentes. Confira rotulos.csv externo, escores por caso e status antes de usar as tabelas. O PDF depende de pdfLaTeX e BibTeX; o arquivo .tex é sempre escrito. Não é necessário instalar X-Processes para executar BPAD: a referência ao estudo identifica o conjunto real escolhido.

## XIII. Conclusão

O modelo da disciplina, iniciado no XML fornecido e executado no BIMP, permite avaliação controlada porque o log limpo foi preservado. Na amostra de 500 casos, raridade_transicoes: F1 0,920. O BPIC12 fornece casos observacionais empregados também pelos pesquisadores de X-Processes; aqui uma cópia recebe alterações controladas para permitir medir detecção e estudar sugestões de reparo. A versão real contém 13 método(s) concluído(s) entre 14 solicitados; as tabelas descrevem apenas números gravados. Sem rótulos humanos de anomalias naturais, recomenda-se revisão humana e repetições com diferentes sementes e taxas.

## References


[1] W. M. P. van der Aalst, *Process Mining: Data Science in Action*, 2nd ed. Springer, 2016.

[2] W. M. P. van der Aalst and J. Carmona, Eds., *Process Mining Handbook*, ser. Lecture Notes in Business Information Processing. Springer, 2022, vol. 448.

[3] M. Fantinato, S. M. Peres, and H. A. Reijers, "X-Processes: Process model discovery with the best balance among fitness, precision, simplicity, and generalization through a genetic algorithm," *Information Systems*, vol. 119, p. 102247, 2023.

[4] S. Suriadi, R. Andrews, A. H. M. ter Hofstede, and M. T. Wynn, "Event log imperfection patterns for process mining: Towards a systematic approach to cleaning event logs," *Information Systems*, vol. 64, pp. 132–150, 2017.

[5] M. M. Breunig, H.-P. Kriegel, R. T. Ng, and J. Sander, "LOF: Identifying density-based local outliers," in *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, 2000, pp. 93–104.

[6] F. T. Liu, K. M. Ting, and Z.-H. Zhou, "Isolation forest," in *2008 Eighth IEEE International Conference on Data Mining*, 2008, pp. 413–422.

[7] M. Weske, *Business Process Management: Concepts, Languages, Architectures*, 4th ed. Springer, 2024.

[8] B. F. van Dongen, "BPI Challenge 2012," Dataset, 2012. [Online]. Available: https://data.4tu.nl/articles/dataset/BPI_Challenge_2012/12689204